Ligue1Scope – Synthèse du projet final

Architectures BD et collecte de données · ESEO 2026-2027 · Nov 7, 2026 · @Enzo

1. Problème, utilisateur, indicateurs et sources

Ligue1Scope répond à une question d'avant-match : **un favori l'est-il vraiment ?** Sur 3 097 matchs de Ligue 1 (2017 à 2026), l'écart Elo fait passer la victoire à domicile de 17 % à 72 %. L'Elo désigne le vainqueur aussi bien que les bookmakers, à 1,4 point près.

Utilisateur, problème et décision. Un analyste performance ou vidéo prépare le dossier de l'adversaire. Le discours d'avant-match (« à notre portée », « match piège ») repose souvent sur l'intuition. Les données lui permettent de doser le niveau de favori et de choisir les facteurs à suivre : rapport de force, terrain, météo.

Question centrale. Avant un match de Ligue 1, dans quelle mesure l'écart de force Elo, l'avantage du terrain et la météo permettent-ils d'anticiper le résultat, comparé au consensus des bookmakers ?

Périmètre. Ligue 1, saisons 2016-2017 à 2025-2026, soit 3 477 matchs. La saison 2016-2017 sert de chauffe à l'Elo et est exclue des KPI. Hors périmètre : joueurs, compositions, événements de match, rentabilité des paris. Fréquence utile : hebdomadaire en saison.

Cas d'usage : en tant qu'analyste, je veux…	KPI
…savoir si le favori Elo gagne vraiment, afin de doser le discours	% de victoires du favori Elo
…mesurer l'avantage du terrain selon l'écart de niveau	% de victoires à domicile par tranche d'écart Elo
…savoir si la météo doit entrer dans la préparation	buts moyens et H/D/A par classe météo
…situer l'Elo face au marché	% de victoires du favori du marché ; accord Elo/marché

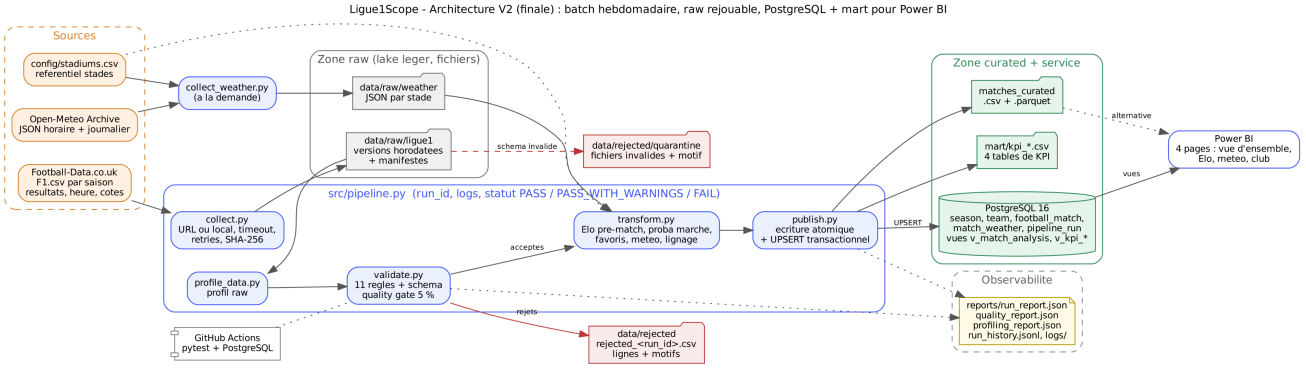
Source	Rôle	Accès	Conditions	Risque
Football-Data.co.uk `F1.csv`	résultats, heure, cotes	HTTP, CSV par saison	gratuit, citer la source	colonnes renommées (`BbAv*` → `Avg*`)
Open-Meteo Archive	température, pluie, vent	API JSON	CC BY 4.0	quotas 429, réanalyse sur grille

Source	Rôle	Accès	Conditions	Risque
ClubElo (écartée)	Elo externe	API CSV	—	HTTP 502 persistant (25/09/2026)

Aucune donnée personnelle ni aucun secret dans le dépôt. Minimisation : seules 10 des 64 à 131 colonnes Football-Data (selon la saison) sont exploitées ; les autres restent dans la zone raw.

2. Pipeline et architecture

Le pipeline est un batch rejouable en une commande, `python src/pipeline.py`. Il enchaîne cinq étapes sous un même `run_id` et finit par l'un de trois statuts : `PASS`, `PASS_WITH_WARNINGS` ou `FAIL`.



1. **Collecte** (`collect.py`) : télécharge `mmz4281/{code}/F1.csv` (ou copie un fichier local), avec timeout, 3 essais et backoff. Le fichier est écrit octet pour octet sous le nom `ligue1_<saison>_<horodatage>.csv`, avec un manifeste SHA-256. S'il est identique à la version précédente, rien n'est écrit.
2. **Profilage** (`profile_data.py`) : volumes, types, manquants, doublons et plages, mesurés sur le raw avant tout nettoyage.
3. **Validation** (`validate.py`) : contrôle de schéma par fichier, 11 règles, puis quality gate à 5 % de rejets.
4. **Transformation** (`transform.py`) : Elo pré-match, probabilités implicites du marché, favoris, jointure météo, colonnes de lignage.
5. **Publication** (`publish.py`) : CSV et Parquet écrits de façon atomique, mart de 4 tables de KPI, UPSERT PostgreSQL en une transaction.

Grain et clé. Une ligne représente un match disputé. La clé métier est (saison, date, domicile, extérieur), d'où `match_id`. Le contrat `config/data_contract.yaml` (v2.0, avec changelog) fixe les 12 champs obligatoires, les règles, la rétention et l'owner. Le dictionnaire décrit les 36 colonnes du curated.

Stockage. Le raw reste en fichiers : c'est la preuve exacte de ce que la source a livré. Le curated est publié en CSV pour la portabilité et en Parquet pour le typage (239 Ko contre 1,1 Mo). PostgreSQL 16 sert Power BI : schéma normalisé `season`, `team`, `football_match`, `match_weather`, journal `pipeline_run`, vue `v_match_analysis` et quatre vues `v_kpi_*`.

Élément	V1 (séances 1-2)	V2 (finale)
Exécution	5 scripts lancés à la main	orchestrateur, `run_id`, logs, statut
Collecte	copie d'un dossier local	URL ou local, nouvelles tentatives, idempotence par SHA-256
Qualité	5 règles	11 règles + schéma + quality gate, quarantaine
Curated	3 CSV quasi identiques, imputations	1 jeu CSV + Parquet, aucune imputation, lignage
Base	remplacement complet	UPSERT sur `row_hash`, migration v1 → v2
Analyse	Elo, météo	+ cotes du marché, saison de chauffe exclue

V1, V2 et lineage des champs en PNG et SVG : `docs/architecture/`.

3. Qualité, incidents et observabilité

Sur les données réelles, les 3 477 lignes passent les 11 règles (0 rejet). La seule alerte est la fraîcheur : le dernier match date du 17/05/2026 et la saison 2026-2027 n'est pas encore collectée. L'exercice d'incident déclenche chaque règle et montre la reprise.

Action en cas d'échec	Règles (dimension)
Rejet avec motif	R1 champs obligatoires (complétude) · R2 date réelle · R3 buts entiers 0-15 (validité) · R4 date dans la saison · R5 FTR = score · R6 domicile ≠ extérieur (cohérence)
Déduplication	R7 clé métier unique, 1re occurrence gardée (unicité)
Signalement	R8 cotes dans [1,01 ; 100], sinon NULL (validité)
Alerte	R9 dernier match < 30 jours (fraîcheur) · R10 ⩾ 70 % des matchs attendus par saison (complétude)

Action en cas d'échec	Règles (dimension)
Blocage	R11 `source_file`, `raw_sha256`, `source_row` présents (traçabilité)
Quarantaine + repli	SCHEMA : fichier vide ou colonne obligatoire absente (validité)

Chaque rejet est conservé dans `data/rejected/rejected_<run_id>.csv`, avec la ligne telle que reçue, son motif, le `run_id` et l'horodatage. Au-delà de 5 % de rejets, le run passe en `FAIL` : rien n'est publié, et le curated comme la base précédents restent intacts.

Idempotence, prouvée trois fois.

- À la collecte, un fichier n'est écrit que si son SHA-256 change.
- La transformation est déterministe : au rejeu, le curated garde le même SHA-256.
- L'UPSERT `ON CONFLICT (match_id) … WHERE row_hash IS DISTINCT FROM …` donne 3 477 insertions au premier run, puis 0 insertion, 0 mise à jour et 3 477 lignes inchangées au second.

Scénario simulé (`incident_drill.py`)	Détection	Statut et reprise
7 lignes invalides (score 42, FTR faux, 31/02, club vide, Rennes-Rennes, date 2019, doublon)	R1 à R7	PASS_WITH_WARNINGS, 7 rejets avec motif
saison livrée deux fois	R7 + gate (8,1 %)	FAIL, rien publié, curated intact
colonne `FTHG` renommée ; fichier vide	SCHEMA	PASS_WITH_WARNINGS, quarantaine et repli
source injoignable	collecte	PASS_WITH_WARNINGS, dernier raw utilisé
base injoignable	publication	FAIL sans écriture partielle ; un rejeu suffit
double exécution	—	curated identique, 0 insertion

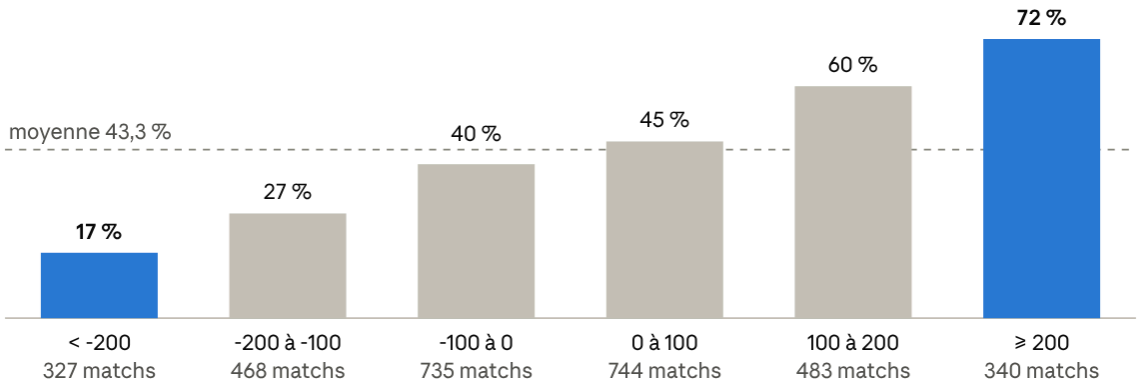
Observabilité et gouvernance. Chaque run écrit `run_report.json` (statut, durées, compteurs, fraîcheur, KPI), `quality_report.json`, `profiling_report.json`, un log, une ligne dans `run_history.jsonl` et dans la table `pipeline_run`. Owner : l'étudiant. Le raw et la quarantaine sont conservés intégralement, les rejets un an. 44 tests pytest tournent en CI avec PostgreSQL.

4. Résultats et produit de données

L'écart Elo est le facteur décisif. La victoire à domicile est multipliée par 4,3 entre les tranches extrêmes, alors que la météo change peu le jeu.

La victoire à domicile passe de 17 % à 72 % selon l'écart Elo

Taux de victoire à domicile par tranche d'écart Elo (domicile – extérieur), 3 097 matchs 2017-2026



Écart Elo pré-match (points) — à gauche le visiteur est plus fort, à droite le club recevant

data/curated/mart/kpi_tranche_elo.csv · run du 07/11/2026 · 3 097 matchs, hors saison de chauffe 2016-2017

Elo contre marché. Le favori Elo gagne 50,8 % des matchs, celui des bookmakers 52,2 %. Les deux désignent le même favori dans 89,4 % des cas. Selon la saison, le favori Elo gagne entre 46,3 % (2018-2019) et 55,6 % (2024-2025) des matchs. Un Elo construit uniquement sur les résultats suffit donc presque pour juger du statut de favori. Les cotes n'ajoutent qu'environ 1,4 point.

Météo. Les buts moyens montent de 2,56 sous 5 °C à 3,01 entre 20 et 25 °C. Selon la pluie, ils restent plats : de 2,72 à 2,78 entre 0 mm et plus de 5 mm. Pour la préparation, la météo reste un facteur secondaire. La couverture météo est de 100 %. Les stades de Marseille, Nice et Strasbourg, d'abord manquants à cause des quotas, ont été repérés par l'indicateur de couverture puis collectés.

Produit. `matches_curated.csv` et `.parquet`, 4 tables de KPI dans `data/curated/mart/` (identiques aux vues `v_kpi_*`), et 4 pages Power BI branchées sur `v_match_analysis` : vue d'ensemble, Elo, météo, club.

Le résultat décrit des associations, pas des causes : blessures, calendrier et compositions ne sont pas contrôlés.

5. Décisions, limites et perspectives

L'architecture retenue est proportionnée au besoin : un batch hebdomadaire, un raw en fichiers et PostgreSQL avec un mart. Le cloud et le streaming ont été écartés faute de besoin mesurable (ADR-001).

Décision	Retenu	Écarté	Raison
Architecture (ADR-001)	raw fichiers + PostgreSQL + mart	fichiers seuls ; cloud + Airflow	~400 matchs/an ; contraintes et vues BI sans coût d'exploitation
Traitement	batch hebdomadaire	streaming	source publiée après chaque journée
Chargement (ADR-002)	UPSERT sur `row_hash`	remplacement complet ; SQLite	idempotence mesurable
Elo	calcul interne, 2016-2017 en chauffe	ClubElo	HTTP 502 ; reproductible hors ligne
Manquants	NULL signalé	imputation (v1)	ne pas fabriquer d'observations
Lot dégradé	gate 5 % + quarantaine	publication partielle	un lot douteux ne remplace pas un lot sain

Limites. L'Elo démarre à 1 500 en 2016, y compris pour les clubs promus. La météo est une réanalyse sur grille, journalière seulement avant 2019-2020. Les cotes servent de référence, pas d'outil de pari.

Perspectives. Planifier le run hebdomadaire et ajouter 2026-2027, ce qui lève l'alerte de fraîcheur. Vérifier les coordonnées des stades. Mesurer la calibration (score de Brier) de l'Elo face aux cotes. Pour la production : coffre à secrets, rôle PostgreSQL en lecture seule, sauvegardes, alerte sur `FAIL`.

Usage d'outils d'IA. Outil : Claude (Anthropic). Tâches assistées, lors de la consolidation finale du 07/11 : revue face au barème, orchestrateur, règles v2, UPSERT, exercice d'incident, documentation. Vérifications : 44 tests, rejeu complet dans un environnement vierge, contrôle des KPI contre Power BI. Parties personnelles : *cadrage et choix du sujet ; évaluation des sources et diagnostic de la panne ClubElo, d'où le choix d'un Elo interne ; collecte des 10 saisons, référentiel des stades et collecteur météo ; première version du pipeline (5 règles, Elo, jointure météo) ; choix de PostgreSQL, schéma, Docker Compose, tests et CI ; description de la chaîne de traitement ; conception des 4 pages Power BI et de leurs mesures DAX*.