Ligue1Scope – Synthèse du projet final

Architectures BD et collecte de données · ESEO 2026-2027 · Nov 7, 2026 · @Enzo

En bref. Ligue1Scope est une chaîne de traitement de données. Elle rassemble dix saisons de Ligue 1 (résultats, cotes des bookmakers, météo au stade), les contrôle, les range dans une base et les présente dans Power BI. Elle répond à une question d'avant-match : l'équipe désignée comme la plus forte gagne-t-elle vraiment, et la météo compte-t-elle ? Tout se rejoue en une commande, et chaque chiffre publié remonte jusqu'au fichier d'origine.

Vocabulaire. Elo : note de force d'une équipe, qui monte quand elle gagne et baisse quand elle perd, d'autant plus que l'adversaire était fort ; l'écart Elo compare les deux équipes avant le match. **Cote, favori du marché** : la cote d'un bookmaker traduit la probabilité qu'il donne à chaque issue ; l'issue jugée la plus probable est le favori du marché. **Saison de chauffe** : 2016-2017, où toutes les équipes partent de la même note ; elle est exclue des indicateurs. **Raw / curated** : zone brute (fichiers tels que reçus) et zone nettoyée (données contrôlées, prêtes à l'usage). **Idempotent** : relancer le pipeline sur les mêmes données redonne exactement le même résultat, sans doublon.

1. Problème, utilisateur, indicateurs et sources

Utilisateur, problème et décision. Un analyste performance ou vidéo prépare le dossier de l'adversaire. Le discours d'avant-match (« à notre portée », « match piège ») repose souvent sur l'intuition. Les données lui permettent de doser le niveau de favori et de choisir les facteurs à suivre : rapport de force, terrain, météo.

Question centrale. Avant un match de Ligue 1, dans quelle mesure l'écart de force Elo, l'avantage du terrain et la météo permettent-ils d'anticiper le résultat, comparé au consensus des bookmakers ?

Périmètre. Ligue 1, saisons 2016-2017 à 2025-2026, soit 3 477 matchs. La saison 2016-2017 sert de chauffe à l'Elo et est exclue des KPI. Hors périmètre : joueurs, compositions, événements de match, rentabilité des paris. Fréquence utile : hebdomadaire en saison.

Cas d'usage : en tant qu'analyste, je veux…	KPI
…savoir si le favori Elo gagne vraiment, afin de doser le discours	% de victoires du favori Elo
…mesurer l'avantage du terrain selon l'écart de niveau	% de victoires à domicile par tranche d'écart Elo

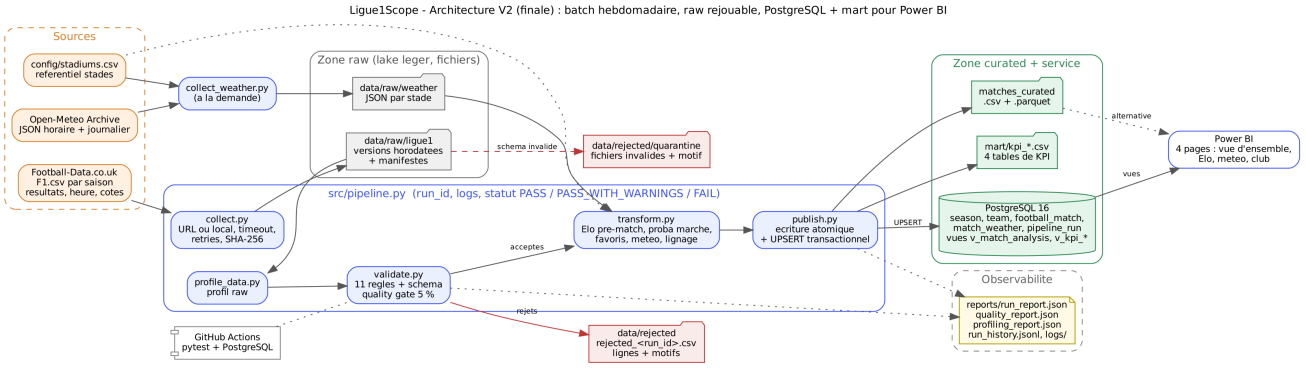
Cas d'usage : en tant qu'analyste, je veux…	KPI
…savoir si la météo doit entrer dans la préparation	buts moyens et H/D/A par classe météo
…situer l'Elo face au marché	% de victoires du favori du marché ; accord Elo/marché

Source	Rôle	Accès	Conditions	Risque
Football-Data.co.uk `F1.csv`	résultats, heure, cotes	HTTP, CSV par saison	gratuit, citer la source	colonnes renommées (`BbAv*` → `Avg*`)
Open-Meteo Archive	température, pluie, vent	API JSON	CC BY 4.0	quotas 429, réanalyse sur grille
ClubElo (écartée)	Elo externe	API CSV	—	HTTP 502 persistant (25/09/2026)

Aucune donnée personnelle ni aucun secret dans le dépôt. Minimisation : seules 10 des 64 à 131 colonnes Football-Data (selon la saison) sont exploitées ; les autres restent dans la zone raw.

2. Pipeline et architecture

Le pipeline est un traitement par lots (batch) relancé en une seule commande. Il enchaîne cinq étapes sous un même identifiant d'exécution et se termine par l'un de trois statuts : réussi (PASS), réussi avec alertes (PASS_WITH_WARNINGS) ou échec (FAIL).



Architecture V2 : sources à gauche, orchestrateur au centre, zones brute, rejets et nettoyée, base PostgreSQL et Power BI à droite, rapports d'observabilité en bas.

1. **Collecte** : télécharge le fichier CSV de chaque saison (ou copie un fichier local), avec délai maximal, 3 essais et attente croissante entre essais. Le fichier est conservé octet pour octet sous un nom horodaté, avec une empreinte (SHA-256) qui prouve son intégrité. S'il est identique à la version précédente, rien n'est écrit.
2. **Profilage** : volumes, types, manquants, doublons et plages de valeurs, mesurés sur les données brutes avant tout nettoyage.
3. **Validation** : contrôle du format de chaque fichier, puis 11 règles par ligne. Un seuil de blocage (quality gate) empêche toute publication au-delà de 5 % de lignes rejetées.
4. **Transformation** : note Elo de chaque équipe avant le match, probabilités tirées des cotes, favori Elo et favori du marché, météo au stade, et colonnes de traçabilité vers le fichier source.
5. **Publication** : fichiers CSV et Parquet écrits en une seule opération (jamais à moitié), 4 tables d'indicateurs, et chargement dans PostgreSQL par insertion ou mise à jour (UPSERT) en une seule transaction.

Grain et clé. Une ligne représente un match disputé. La clé métier est le quadruplet (saison, date, domicile, extérieur), d'où un identifiant unique par match. Le contrat de données (fichier YAML versionné, v2.0) fixe les 12 champs obligatoires, les règles, la durée de conservation et le responsable. Le dictionnaire décrit les 36 colonnes du jeu nettoyé.

Stockage. Les données brutes restent en fichiers : c'est la preuve exacte de ce que la source a livré. Le jeu nettoyé est publié en CSV pour la portabilité et en Parquet pour le typage (239 Ko contre 1,1 Mo). PostgreSQL 16 sert Power BI : schéma normalisé (saisons, équipes, matchs, météo), journal des exécutions, et vues prêtes pour l'analyse.

3. Qualité, incidents et observabilité

Sur les données réelles, les 3 477 lignes passent les 11 règles (0 rejet). La seule alerte est la fraîcheur : le dernier match date du 17/05/2026 et la saison 2026-2027 n'est pas encore collectée. L'exercice d'incident déclenche chaque règle et montre la reprise.

Action en cas d'échec	Règles (dimension)
Rejet avec motif	R1 champs obligatoires (complétude) · R2 date réelle · R3 buts entiers 0-15 (validité) · R4 date dans la saison · R5 résultat cohérent avec le score · R6 domicile ≠ extérieur (cohérence)
Déduplication	R7 clé métier unique, 1re occurrence gardée (unicité)
Signalement	R8 cotes dans [1,01 ; 100], sinon NULL (validité)

Action en cas d'échec	Règles (dimension)
Alerte	R9 dernier match < 30 jours (fraîcheur) · R10 ⩾ 70 % des matchs attendus par saison (complétude)
Blocage	R11 chaque ligne garde son fichier, son empreinte et son numéro de ligne d'origine (traçabilité)
Quarantaine + repli	SCHEMA : fichier vide ou colonne obligatoire absente (validité)

Chaque ligne rejetée est conservée dans un fichier de rejets, telle que reçue, avec son motif et l'exécution concernée : rien n'est supprimé en silence. Au-delà de 5 % de rejets, l'exécution échoue (FAIL) : rien n'est publié, et le jeu nettoyé comme la base précédents restent intacts.

Idempotence, prouvée trois fois.

- À la collecte, un fichier n'est écrit que si son empreinte change.
- La transformation est déterministe : relancée, elle produit un fichier identique octet pour octet.
- En base, un match n'est inséré ou mis à jour que si son contenu a changé : 3 477 insertions au premier run, puis 0 insertion, 0 mise à jour et 3 477 lignes inchangées au second.

Scénario simulé (exercice automatisé)	Détection	Statut et reprise
7 lignes invalides (score 42, FTR faux, 31/02, club vide, Rennes-Rennes, date 2019, doublon)	R1 à R7	PASS_WITH_WARNINGS, 7 rejets avec motif
saison livrée deux fois	R7 + gate (8,1 %)	FAIL, rien publié, curated intact
colonne des buts renommée ; fichier vide	SCHEMA	PASS_WITH_WARNINGS, quarantaine et repli
source injoignable	collecte	PASS_WITH_WARNINGS, dernier raw utilisé
base injoignable	publication	FAIL sans écriture partielle ; un rejeu suffit
double exécution	—	curated identique, 0 insertion

Observabilité et gouvernance. Chaque exécution produit un rapport (statut, durées, compteurs, fraîcheur, indicateurs), un rapport qualité, un profil des données brutes, un journal et une ligne d'historique en base. Responsable du jeu de données : l'étudiant. Les données brutes et la quarantaine sont conservées intégralement, les rejets un an. 44 tests automatiques tournent à chaque envoi sur GitHub (intégration continue, avec PostgreSQL).

4. Résultats et produit de données

L'écart Elo est le facteur décisif. La victoire à domicile est multipliée par 4,3 entre les tranches extrêmes, alors que la météo change peu le jeu.

Elo contre marché. Le favori Elo gagne 50,8 % des matchs, celui des bookmakers 52,2 %. Les deux désignent le même favori dans 89,4 % des cas. Selon la saison, le favori Elo gagne entre 46,3 % (2018-2019) et 55,6 % (2024-2025) des matchs. Un Elo construit uniquement sur les résultats suffit donc presque pour juger du statut de favori. Les cotes n'ajoutent qu'environ 1,4 point.

Météo. Les buts moyens montent de 2,56 sous 5 °C à 3,01 entre 20 et 25 °C. Selon la pluie, ils restent plats : de 2,72 à 2,78 entre 0 mm et plus de 5 mm. Pour la préparation, la météo reste un facteur secondaire. La couverture météo est de 100 %. Les stades de Marseille, Nice et Strasbourg, d'abord manquants à cause des quotas, ont été repérés par l'indicateur de couverture puis collectés.

Produit. Le jeu nettoyé (CSV et Parquet), 4 tables d'indicateurs et un tableau de bord Power BI de 4 pages branché sur PostgreSQL : vue d'ensemble, Elo et résultats (la page qui répond à la question centrale), météo, comparaison des équipes. Les captures des 4 pages sont en annexe.

5. Décisions, limites et perspectives

Décision	Retenu	Écarté	Raison
Architecture (ADR-001)	raw fichiers + PostgreSQL + mart	fichiers seuls ; cloud + Airflow	~400 matchs/an : contraintes et vues BI sans coût d'exploitation
Traitement	batch hebdomadaire	streaming	source publiée après chaque journée
Chargement (ADR-002)	UPSERT, mise à jour si la ligne change	remplacement complet ; SQLite	idempotence mesurable

Décision	Retenu	Écarté	Raison
Elo	calcul interne, 2016-2017 en chauffe	ClubElo	HTTP 502 ; reproductible hors ligne
Manquants et lots douteux	NULL signalé ; seuil de 5 % + quarantaine	imputation ; publication partielle	ne pas fabriquer de données ni publier un lot douteux

Limites. L'Elo démarre à 1 500 en 2016, y compris pour les clubs promus. La météo est une réanalyse sur grille, journalière seulement avant 2019-2020. Les cotes servent de référence, pas d'outil de pari.

Perspectives. Planifier le run hebdomadaire et ajouter 2026-2027 ; mesurer la calibration de l'Elo face aux cotes (score de Brier) ; en production, coffre à secrets, accès en lecture seule, sauvegardes et alerte en cas d'échec.

Annexe : évolution de l'architecture V1 → V2

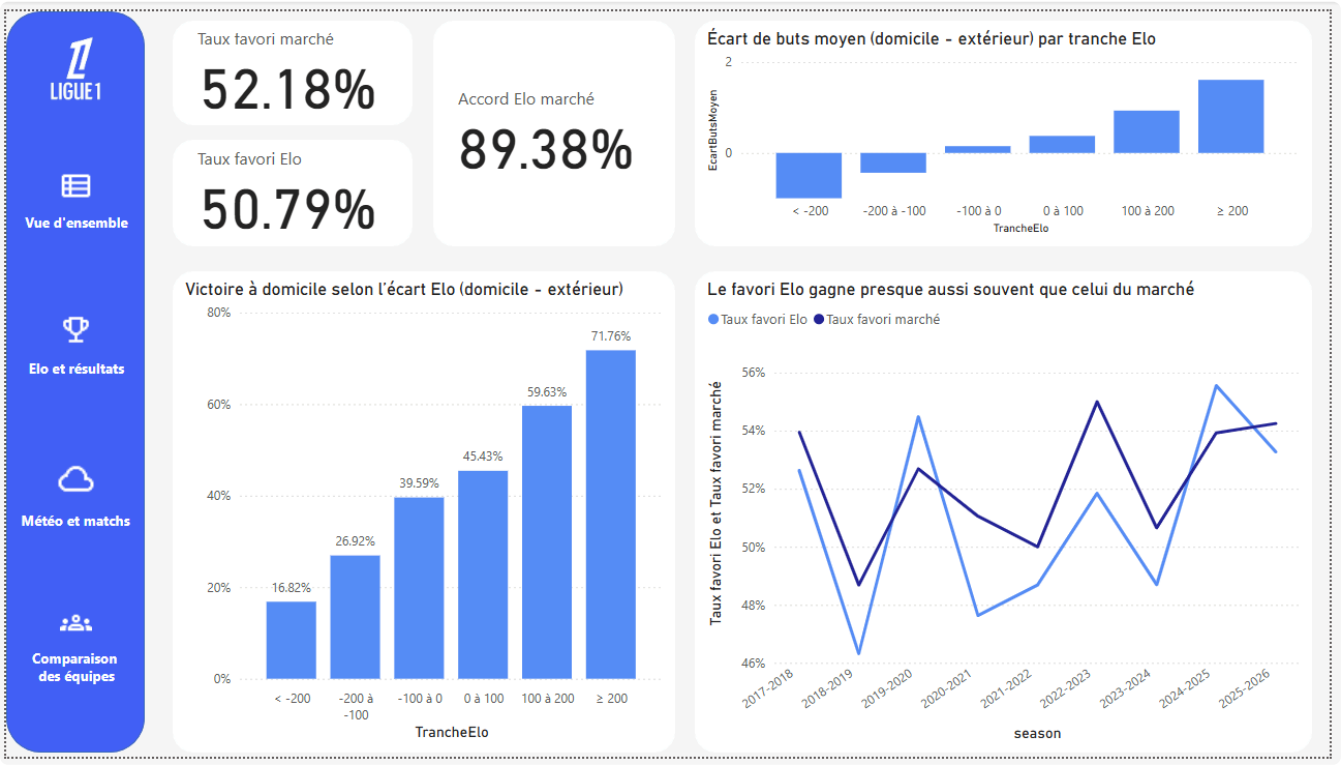
Élément	V1 (séances 1-2)	V2 (finale)
Exécution	5 scripts lancés à la main	orchestrateur, identifiant d'exécution, journaux, statut
Collecte	copie d'un dossier local	URL ou local, nouvelles tentatives, idempotence par SHA-256
Qualité	5 règles	11 règles + schéma + quality gate, quarantaine
Curated	3 CSV quasi identiques, imputations	1 jeu CSV + Parquet, aucune imputation, lignage
Base	remplacement complet	UPSERT (mise à jour seulement si la ligne change), migration sans perte
Analyse	Elo, météo	+ cotes du marché, saison de chauffe exclue

Schémas V1, V2 et lineage des champs (PNG, SVG) : dossier `docs/architecture/` du dépôt.

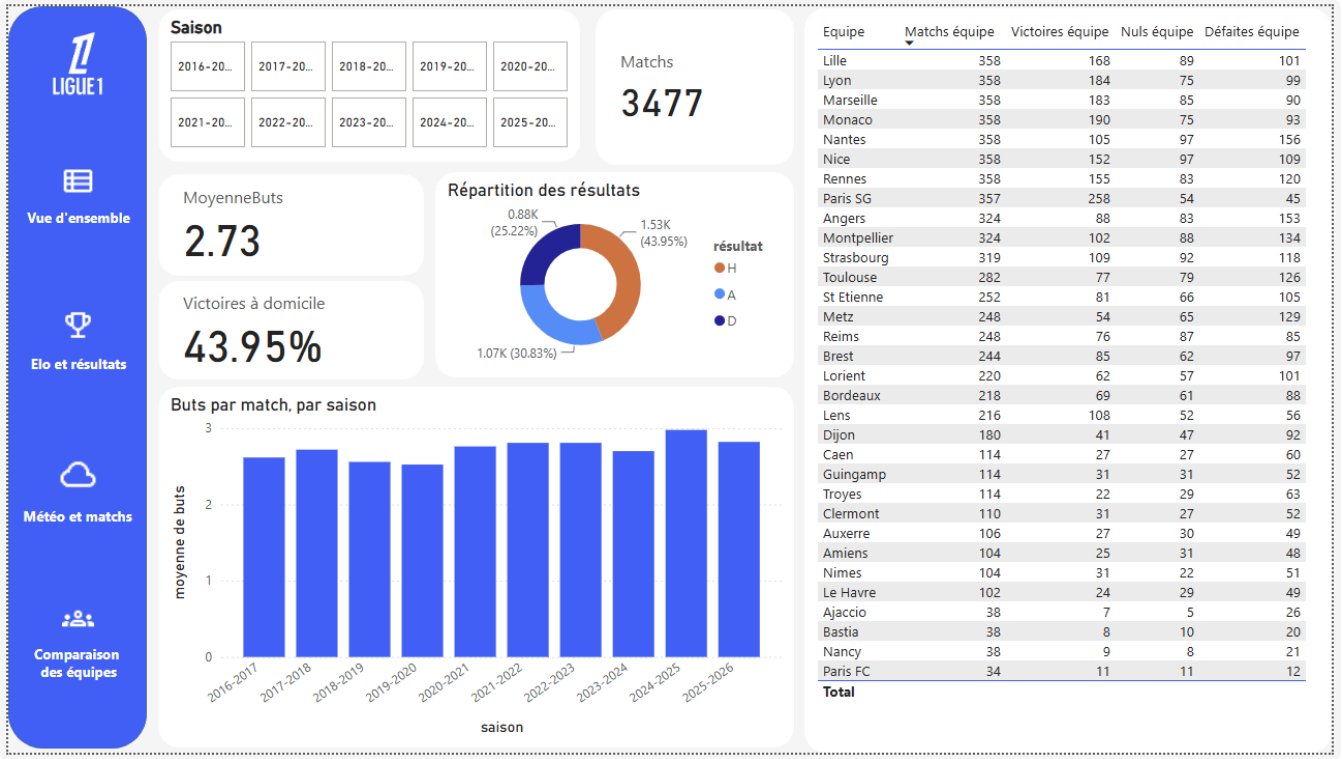
Annexe : tableau de bord Power BI

Les 4 pages du rapport `ProjetLigue1.pbix`, branché sur la base PostgreSQL.

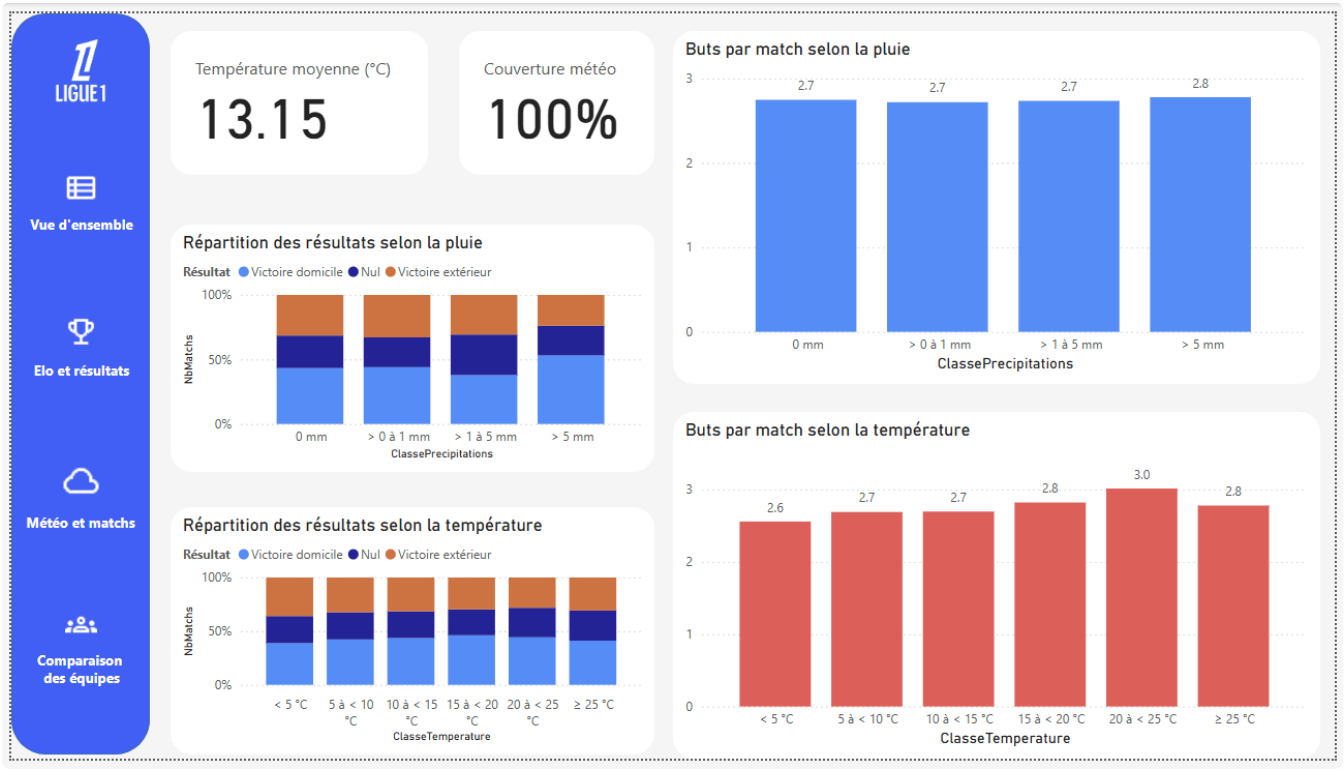
Elo et résultats : répond à la question centrale. La victoire à domicile passe de 17 % à 72 % selon l'écart Elo ; le favori Elo gagne 50,8 % des matchs, contre 52,2 % pour celui du marché (hors saison de chauffe).



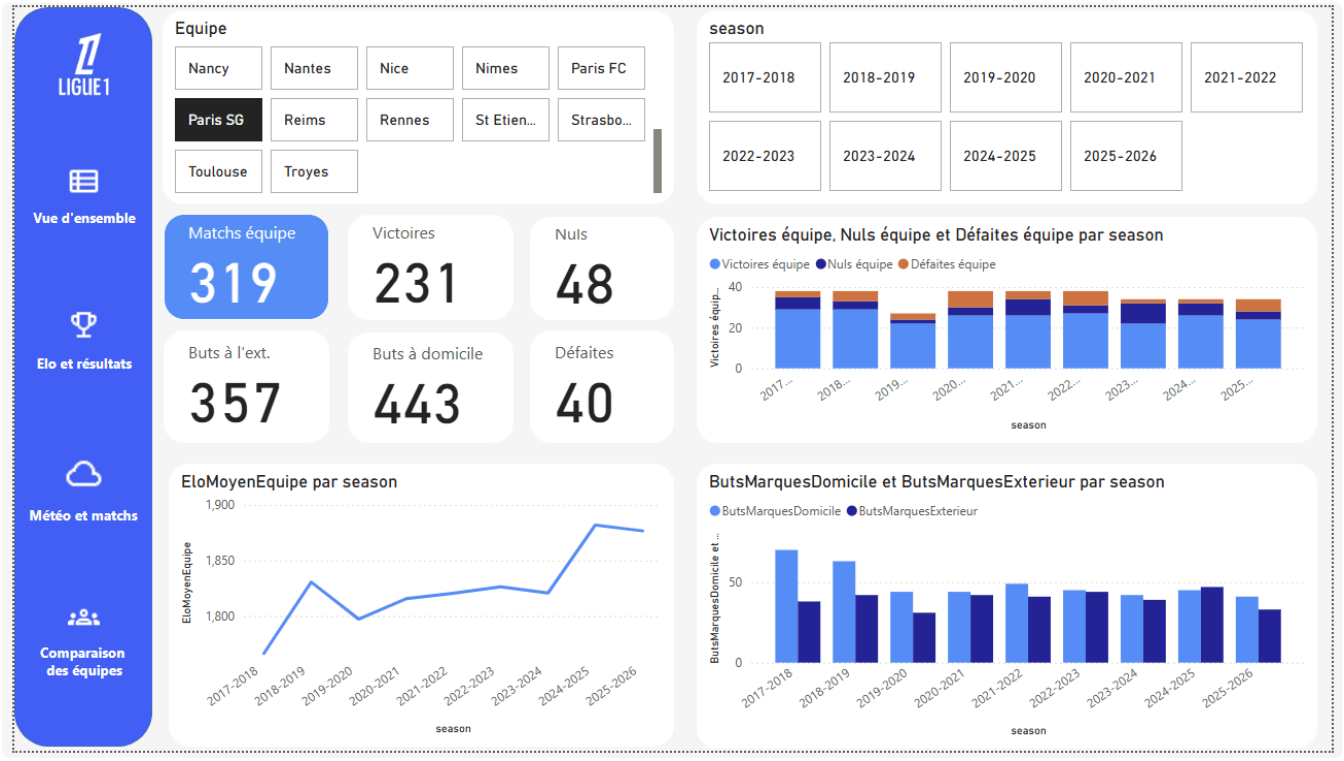
Vue d'ensemble : volumes, buts par match par saison, répartition des résultats, bilan par club.



Météo et matchs : buts et résultats selon la pluie et la température, couverture météo de 100 %.



Comparaison des équipes : bilan, Elo moyen et buts d'un club par saison (ici le Paris SG).



Annexe : usage d'outils d'IA

Outil : Claude (Anthropic). Tâches assistées, lors de la consolidation finale du 07/11 : revue face au barème, orchestrateur, règles v2, UPSERT, exercice d'incident, documentation et rédaction de cette synthèse. Vérifications : 44 tests, rejeu complet dans un environnement vierge, contrôle des KPI contre Power BI.

Parties réalisées personnellement : cadrage et choix du sujet ; évaluation des sources et diagnostic de la panne ClubElo, d'où le choix d'un Elo interne ; collecte des 10 saisons, référentiel des stades et collecteur météo ; première version du pipeline (5 règles, Elo, jointure météo) ; choix de PostgreSQL, schéma, Docker Compose, tests et CI ; description de la chaîne de traitement ; conception des 4 pages Power BI et de leurs mesures DAX.